

Makine Öğrenmesinde Özellik Seçimi: Filtreleme, Sarmalayıcı ve Gömülü Yöntemlerin Karşılaştırmalı Analizi

Mohammed Izedin Mohammed

Öğrenci No: 255B7003

Makine Öğrenmesi Dersi - Ödev 2

Ocak 2026

Özet: Bu çalışmada, makine öğrenmesi modellerinde özellik seçiminin model performansı üzerindeki etkisi sistematik olarak incelenmiştir. Online News Popularity veri seti üzerinde filtreleme (Pearson korelasyonu), sarmalayıcı (RFE) ve gömülü (Random Forest önem) yöntemleri uygulanmıştır. 59 özellikten 15 özelliğe indirgeme yapılarak Lojistik Regresyon sınıflandırıcısı ile performans değerlendirilmesi gerçekleştirilmiştir. Sonuçlar, tüm özelliklerle %65.62 doğruluk elde edilirken, optimal özellik sayısı araştırmasıyla 30 özellik kullanarak %65.29 doğruluk elde edildiğini göstermektedir. Bu bulgular, özellik seçiminin boyut indirgeme sağlarken performansı koruyabildiğini ortaya koymaktadır.

I. Giriş

Makine öğrenmesi uygulamalarında yüksek boyutlu veri setleriyle çalışmak, hesaplama maliyeti ve model performansı açısından önemli zorluklar ortaya çıkarmaktadır. Özellik seçimi, bu zorlukların üstesinden gelmek için kullanılan temel tekniklerden biridir. Doğru özellik seçimi, modelin genelleme yeteneğini artırırken aşırı öğrenme riskini azaltmakta ve yorumlanabilirliği geliştirmektedir.

Literatürde özellik seçimi yöntemleri üç ana kategoride incelenmektedir:

- Filtreleme Yöntemleri:** Model bağımsız istatistiksel ölçütler kullanarak özellikleri değerlendirir.
- Sarmalayıcı Yöntemler:** Bir model kullanarak özellik alt kümelerini değerlendirir.
- Gömülü Yöntemler:** Model eğitimi sırasında özellik seçimi yapar.

Bu çalışma kapsamında aşağıdaki araştırma soruları yanıtlanmaktadır:

- Farklı özellik seçimi yöntemleri hangi özellikleri seçmektedir?
- Özellik seçimi model performansını nasıl etkilemektedir?
- Optimal özellik sayısı nedir?

II. Veri Seti

Çalışmada Mashable haber sitesinden toplanan Online News Popularity veri seti kullanılmıştır. Veri seti özellikleri:

Tablo 1 veri setinin temel istatistiklerini özetlemektedir.

Özellik	Değer
Toplam örnek sayısı	39,644
Özellik sayısı	59 (url hariç)
Hedef değişken	Popülerlik (shares $\geq 1400 \rightarrow 1$, değilse $\rightarrow 0$)
Sınıf 0 (Popüler değil)	18,490 (%46.6)
Sınıf 1 (Popüler)	21,154 (%53.4)

Özellik Kategorileri:

- İçerik:** Kelime sayısı, benzersiz token oranı, stop word oranı
- Bağlantılar:** Hiper link sayısı, görsel sayısı, video sayısı
- Anahtar Kelimeler:** Min/max/avg anahtar kelime metrikleri
- Kanal:** Yaşam tarzı, eğlence, iş, sosyal medya, teknoloji, dünya
- Zaman:** Yayın günü, hafta sonu yayını
- NLP:** Başlık/metin polaritesi ve subjektivitesi

III. Metodoloji

A. Veri Ön İşleme

Lojistik Regresyon gibi gradyan tabanlı algoritmalar için özellik ölçeklendirme kritik öneme sahiptir. StandardScaler kullanılarak tüm özellikler standartlaştırılmıştır ($\mu=0$, $\sigma=1$). Ölçeklendirme parametreleri yalnızca eğitim verisinden hesaplanarak test verisine uygulanmıştır (veri sızıntısı önleme).

B. Özellik Seçimi Yöntemleri

1) Filtreleme Yöntemi - Pearson Korelasyonu: İlk olarak, özellikler arası çoklu doğrusallığı (multicollinearity) tespit etmek amacıyla özellikler arasındaki Pearson korelasyon matrisi hesaplanmıştır. Yüksek korelasyona sahip ($|r| > 0.9$) özellik çiftleri belirlenerek, fazlalığı azaltmak için bu özelliklerden biri elenmiştir. Ardından, kalan özellikler arasından hedef değişken ile en yüksek korelasyona sahip 15 özellik seçilmiştir.

2) Sarmalayıcı Yöntem - RFE: Recursive Feature Elimination, Lojistik Regresyon modeli kullanarak en az önemli özellikleri iteratif olarak elemektedir. 15 özellik kalana kadar eleme yapılmıştır.

3) Gömülü Yöntem - Random Forest: 100 karar ağacı ile eğitilen Random Forest sınıflandırıcısından özellik önem skorları elde edilmiştir. En yüksek öneme sahip 15 özellik seçilmiştir.

C. Değerlendirme Stratejisi

Model performansı, 5-katlı stratified çapraz doğrulama ile değerlendirilmiştir. Her katlamada sınıf oranları korunmuştur. Regularizasyon parametresi (C) grid search ile optimize edilmiştir: $C \in \{0.001, 0.01, 0.1, 1, 10, 100\}$.

IV. Sonuçlar

A. Filtreleme Yöntemi Sonuçları

Pearson korelasyonu ile seçilen 15 özellik arasından ilk 10 özellik aşağıda verilmiştir:

Tablo 2 filtreleme yöntemi ile seçilen ilk 10 özelliğin hedef ile mutlak korelasyonunu göstermektedir.

Sıra	Özellik	Korelasyon
1	LDA_02	0.1603
2	kw_avg_avg	0.1562
3	is_weekend	0.1387
4	data_channel_is_entertainment	0.1129
5	data_channel_is_socmed	0.1103
6	weekday_is_saturday	0.1079
7	data_channel_is_tech	0.1044
8	LDA_04	0.0960
9	num_hrefs	0.0921
10	kw_min_avg	0.0908

B. Sarmalayıcı Yöntem Sonuçları

RFE ile seçilen 15 özellik: n_non_stop_words, n_non_stop_unique_tokens, data_channel_is_socmed, data_channel_is_tech, kw_min_min, kw_max_min, kw_avg_min, kw_avg_max, kw_min_avg, kw_max_avg, kw_avg_avg, is_weekend, LDA_01, LDA_02, LDA_03

C. Gömülü Yöntem Sonuçları

Random Forest özellik önem sıralaması (ilk 10):

Sıra	Özellik	Önem
1	kw_avg_avg	0.0697
2	kw_max_avg	0.0630
3	self_reference_min_shares	0.0568
4	self_reference_avg_sharess	0.0449
5	LDA_02	0.0378
6	is_weekend	0.0324
7	timedelta	0.0320
8	kw_min_avg	0.0298
9	LDA_01	0.0279
10	self_reference_max_shares	0.0262

D. Model Performans Karşılaştırması

Tablo 3 test seti üzerindeki performans metriklerini karşılaştırmaktadır.

Yöntem	Özellik Sayısı	Accuracy	Precision	Recall	F1-Score	Eğitim Süresi
Tüm Özellikler	59	65.62%	67.03%	70.01%	68.49%	~1.25 sn
Filtreleme (Pearson)	15	64.36%	65.49%	70.20%	67.76%	~0.85 sn
Sarmalayıcı (RFE)	15	64.64%	65.94%	69.75%	67.79%	~45.20 sn
Gömülü (RF)	15	63.96%	64.41%	72.54%	68.23%	~3.40 sn
Optimal	30	65.29%	66.64%	69.98%	68.27%	~55.10 sn

E. Eğitim / Doğrulama / Test Karşılaştırması

Ödev yönergesine uygun olarak başarı değerleri eğitim (train), doğrulama (5-fold CV) ve test için ayrı ayrı Tablo 4'te verilmiştir.

Yöntem	Eğitim Acc	Eğitim F1	CV Acc (±std)	CV F1 (±std)	Test Acc	Test F1
Tüm Özellikler	65.57%	68.47%	65.25% ± 0.23%	68.20% ± 0.17%	65.62%	68.49%
Filtreleme	64.29%	67.61%	64.31% ± 0.62%	67.63% ± 0.47%	64.36%	67.76%
Sarmalayıcı	64.83%	67.92%	64.81% ± 0.62%	67.91% ± 0.44%	64.64%	67.79%
Gömülü	63.78%	67.85%	63.86% ± 0.64%	67.88% ± 0.41%	63.96%	68.23%
Optimal (30)	65.28%	68.31%	65.28% ± 0.34%	68.28% ± 0.39%	65.29%	68.27%

F. Seçilen Özellikler ve Ortaklık

Tablo 5'te filtreleme, RFE ve Random Forest yöntemlerinin seçtiği 15'er özellik sıralı olarak verilmiştir. Ortak seçilen özellikler ayrıca listelenmiştir.

Sıra	Filtreleme (Pearson)	Sarmalayıcı (RFE)	
1	LDA_02	n_non_stop_words	
2	kw_avg_avg	n_non_stop_unique_tokens	
3	is_weekend	data_channel_is_socmed	self
4	data_channel_is_entertainment	data_channel_is_tech	self
5	data_channel_is_socmed	kw_min_min	
6	weekday_is_saturday	kw_max_min	
7	data_channel_is_tech	kw_avg_min	
8	LDA_04	kw_avg_max	
9	num_hrefs	kw_min_avg	
10	kw_min_avg	kw_max_avg	self
11	weekday_is_sunday	kw_avg_avg	data_
12	LDA_01	is_weekend	
13	num_keywords	LDA_01	
14	global_sentiment_polarity	LDA_02	
15	global_subjectivity	LDA_03	n_n

Not: Optimal yöntemde 30 özellik seçilmiştir (performans en yüksek olacak şekilde). Bu özellikler results/metrics.txt dosyasında listelenmiştir.

Üç yöntemin de seçtiği ortak özellikler (5 adet):

- kw_avg_avg - Ortalama anahtar kelime performansı
- kw_min_avg - Minimum anahtar kelime ortalaması
- LDA_01 - Konu modelleme özelliği 1
- LDA_02 - Konu modelleme özelliği 2
- is_weekend - Hafta sonu yayını


Önemli Bulgu: kw_avg_avg ve ilgili anahtar kelime metrikleri tüm yöntemlerde üst sıralarda yer almıştır. Filtreleme yönteminde en yüksek hedef korelasyonu LDA_02 özelliğinde gözlemlenmiştir.

F. Regularizasyon Analizi

C Değeri	CV Accuracy	Yorum
0.001	64.99%	Güçlü regularizasyon - underfitting
0.01	65.21%	Güçlü regularizasyon
0.1	65.23%	Dengeli
1.0	65.23%	Dengeli
10	65.24%	Zayıf regularizasyon
100	65.25%	Optimal

G. Karışıklık Matrisi (Tüm Özellikler)

Şekil 1 en başarılı yönteme ait karışıklık matrisi görselleştirmesini, Tablo 6 ise sayısal değerlerini göstermektedir.




Şekil 1: En iyi model için karışıklık matrisi görselleştirmesi

Tablo 6: En başarılı yöntem için karışıklık matrisi (sayısal değerler).

	Tahmin: 0	Tahmin: 1
Gerçek: 0	2241 (TN)	1457 (FP)
Gerçek: 1	1269 (FN)	2962 (TP)

Yorumlama:

- Specificity (TN Rate): %60.6 - Popüler olmayan haberleri tespit
- Recall (TP Rate): %70.0 - Popüler haberleri tespit
- Model, popüler haberleri yakalamada daha başarılıdır



Şekil 2: Özellik seçimi yöntemlerinin performans karşılaştırması

Şekil 2, farklı özellik seçimi stratejilerinin test seti başarımını görsel olarak karşılaştırmaktadır.

V. Tartışma

A. Araştırma Sorularının Yanıtları

S1: Farklı yöntemler hangi özellikleri seçti?

Her üç yöntem de anahtar kelime metriklerini (kw_avg_avg) en önemli özellik olarak belirledi. Ancak yöntemler arasında önemli farklılıklar mevcuttur: RFE, kanal özelliklerini (data_channel_is_tech) önemli bulurken, Pearson korelasyonu hafta sonu yayını (is_weekend) vurgulamaktadır.

S2: Özellik seçimi performansı nasıl etkilendi?

59 özellikten 15'e indirgeme, doğrulukta yaklaşık %1-3 düşüşe neden oldu. Ancak bu, %75 boyut azaltma karşılığında kabul edilebilir bir trade-off'tur. Üç özellik seçimi yöntemi arasında en iyi test doğruluğu RFE ile elde edilmiştir (%64.64).

S3: Optimal özellik sayısı nedir?

RFE tabanlı arama sonuçlarına göre 30 özellik, performans (%65.29) ve boyut indirgeme (%50) arasında optimal dengeyi sağlamaktadır.

B. Pratik Çıkarımlar

- **Anahtar Kelime Stratejisi:** kw_avg_avg ve ilgili metriklerin önemli olması, haberlerin popülerliğini artırmak için anahtar kelime optimizasyonunun kritik olduğunu göstermektedir.
- **Hafta Sonu Etkisi:** is_weekend özelliğinin önemli olması, kullanıcı davranışlarının zamana bağlı değişkenliğini yansıtmaktadır.
- **Self-Referans:** Önceki popüler haberlere referans verme, yeni haberlerin popülerliğini artırmaktadır.

C. Sınırlılıklar

1. **Model Çeşitliliği:** Yalnızca Lojistik Regresyon kullanılmıştır. SVM, Neural Networks gibi farklı modeller farklı sonuçlar verebilir.
2. **Özellik Etkileşimleri:** Özellikler arası etkileşimler incelenmemiştir.
3. **Zamansal Faktörler:** Veri setindeki zamansal dinamikler dikkate alınmamıştır.

VI. Sonuç

Bu çalışmada, Online News Popularity veri seti üzerinde üç farklı özellik seçimi yöntemi karşılaştırmalı olarak incelenmiştir. Ana bulgular:

- **Optimal Özellik Sayısı:** 30 özellik ile %65.29 doğruluk elde edilmiştir.
- **En İyi Sonuç:** Tüm özellikler ile %65.62 test doğruluğu elde edilmiştir. Özellik seçimi yöntemleri arasında en iyi sonuç RFE ile %64.64'tür.
- **Kritik Özellikler:** kw_avg_avg, kw_min_avg ve LDA tabanlı özellikler yöntemler arasında sıklıkla üst sıralarda yer almıştır.
- **Performans Trade-off:** %75 boyut azaltma karşılığında yalnızca %1-3 performans kaybı yaşanmıştır.

Gelecek çalışmalarda, farklı sınıflandırıcılar ile karşılaştırma ve özellik etkileşimlerinin analizi önerilmektedir.

VII. Referanslar

1. I. Guyon and A. Elisseeff, "An introduction to variable and feature selection," Journal of Machine Learning Research, vol. 3, pp. 1157-1182, 2003.
2. S. Chandrashekar and F. Sahin, "A survey on feature selection methods," Computers & Electrical Engineering, vol. 40, no. 1, pp. 16-28, 2014.
3. I. Guyon et al., "Gene selection for cancer classification using support vector machines," Machine Learning, vol. 46, pp. 389-422, 2002.
4. L. Breiman, "Random forests," Machine Learning, vol. 45, no. 1, pp. 5-32, 2001.
5. K. Fernandes et al., "A proactive intelligent decision support system for predicting the popularity of online news," EPIA 2015, pp. 535-546, 2015.
6. F. Pedregosa et al., "Scikit-learn: Machine learning in Python," Journal of Machine Learning Research, vol. 12, pp. 2825-2830, 2011.