

Makine Öğrenmesinde Özellik Seçimi: Filtreleme, Sarmalayıcı ve Gömülü Yöntemlerin Karşılaştırmalı Analizi

Mohammed Izedin Mohammed

Öğrenci No: 255B7003

Makine Öğrenmesi Dersi - Ödev 2

Ocak 2026

Özet: Bu ödevde, özellik seçiminin sınıflandırma performansına etkisini inceledim. Online News Popularity veri seti üzerinde üç farklı yöntem denedim: filtreleme (Pearson korelasyonu), sarmalayıcı (RFE) ve gömülü (Random Forest). Tüm özellikleri kullanan temel model (baseline) %65.62 doğruluk verirken, özellik seçimi yöntemleri arasında en iyi sonucu RFE ile elde ettim. RFE tabanlı optimal 30 özellik seçimi ile %65.29 doğruluk elde edildi. Bu sonuçlar, özellik sayısını yarıya indirirken performansın neredeyse korunabildiğini gösteriyor.

I. Giriş

Makine öğrenmesinde çok sayıda özellik kullanmak her zaman iyi sonuç vermiyor. Gereksiz veya ilgisiz özellikler modelin performansını düşürebiliyor ve eğitim süresini uzatıyor. Bu yüzden hangi özelliklerin kullanılacağını seçmek önemli bir adım.

Özellik seçimi için üç temel yaklaşım var:

- Filtreleme Yöntemleri:** İstatistiksel ölçütlerle özellikleri sıralayıp en iyilerini seçiyor.
- Sarmalayıcı Yöntemler:** Bir model kullanarak hangi özelliklerin daha iyi çalıştığını buluyor.
- Gömülü Yöntemler:** Model eğitilirken otomatik olarak önemli özellikleri belirliyor.

Bu ödevde şu soruları cevaplamaya çalıştım:

- Her yöntem hangi özellikleri seçiyor?
- Özellik seçimi doğruluğu nasıl etkiliyor?
- Kaç özellik kullanmak en iyi sonucu veriyor?

II. Veri Seti

Çalışmada Mashable haber sitesinden toplanan Online News Popularity veri seti kullanılmıştır. Veri seti özellikleri:

Tablo 1 veri setinin temel istatistiklerini özetlemektedir.

Özellik	Değer
Toplam örnek sayısı	39,644
Özellik sayısı	59 (url hariç)
Hedef değişken	Popülerlik ($\text{shares} \geq 1400 \rightarrow 1$, değilse $\rightarrow 0$)
Sınıf 0 (Popüler değil)	18,490 (%46.6)
Sınıf 1 (Popüler)	21,154 (%53.4)

Özellik Kategorileri:

- **İçerik:** Kelime sayısı, benzersiz token oranı, stop word oranı
- **Bağlantılar:** Hiper link sayısı, görsel sayısı, video sayısı
- **Anahtar Kelimeler:** Min/max/avg anahtar kelime metrikleri
- **Kanal:** Yaşam tarzı, eğlence, iş, sosyal medya, teknoloji, dünya
- **Zaman:** Yayın günü, hafta sonu yayını
- **NLP:** Başlık/metin polaritesi ve subjektivitesi

III. Metodoloji

A. Veri Ön İşleme

Veri setinden ayırt edici bilgi içermeyen `url` sütunu çıkarılmıştır. `timedelta` özelliği UCI dokümantasyonunda non-predictive olarak belirtilmesine rağmen, bazı çalışmalarda zaman faktörünün popülerlik üzerinde etkisi olabileceği düşünülerek analize dahil edilmiştir. Hedef değişken `shares` için 1400 eşik değeri kullanılarak ikili sınıflandırma yapılmıştır ($\text{shares} \geq 1400 \rightarrow 1$, değilse $\rightarrow 0$). Veri %80 eğitim, %20 test olarak bölünmüştür.

Lojistik Regresyon gibi gradyan tabanlı algoritmalar için özellik ölçeklendirme kritik öneme sahiptir. `StandardScaler` kullanılarak tüm özellikler standartlaştırılmıştır ($\mu=0$, $\sigma=1$). Ölçeklendirme parametreleri yalnızca eğitim verisinden hesaplanarak test verisine uygulanmıştır (veri sızıntısı önleme).

B. Özellik Seçimi Yöntemleri

1) Filtreleme Yöntemi - Pearson Korelasyonu: İlk olarak, özellikler arası çoklu doğrusallığı (multicollinearity) tespit etmek amacıyla özellikler arasındaki Pearson korelasyon matrisi hesaplanmıştır. Yüksek korelasyona sahip ($|p| > 0.9$) özellik çiftleri belirlenerek, fazlalığı azaltmak için bu özelliklerden biri elenmiştir. Ardından, kalan özellikler arasından hedef değişken ile en yüksek korelasyona sahip 15 özellik seçilmiştir.

2) Sarmalayıcı Yöntem - RFE: Recursive Feature Elimination, Lojistik Regresyon modeli kullanarak en az önemli özellikleri iteratif olarak elemektedir. 15 özellik kalana kadar eleme yapılmıştır.

3) Gömülü Yöntem - Random Forest: 100 karar ağacı ile eğitilen Random Forest sınıflandırıcısından özellik önem skorları elde edilmiştir. En yüksek öneme sahip 15 özellik seçilmiştir.

C. Değerlendirme Stratejisi

Model performansı, 5-katlı stratified çapraz doğrulama ile değerlendirilmiştir. Her katlamada sınıf oranları korunmuştur. Regularizasyon parametresi (C) grid search ile optimize edilmiştir: $C \in \{0.001, 0.01, 0.1, 1, 10, 100\}$.

IV. Sonuçlar

A. Filtreleme Yöntemi Sonuçları

Pearson korelasyonu ile seçilen 15 özellik arasından ilk 10 özellik aşağıda verilmiştir:

Tablo 2 filtreleme yöntemi ile seçilen ilk 10 özelliğin hedef ile mutlak korelasyonunu göstermektedir.

Sıra	Özellik	Korelasyon
1	LDA_02	0.1603
2	kw_avg_avg	0.1562
3	is_weekend	0.1387
4	data_channel_is_entertainment	0.1129
5	data_channel_is_socmed	0.1103
6	weekday_is_saturday	0.1079
7	data_channel_is_tech	0.1044
8	LDA_04	0.0960
9	num_hrefs	0.0921
10	kw_min_avg	0.0908

B. Sarmalayıcı Yöntem Sonuçları

RFE ile seçilen 15 özellik: n_non_stop_words, n_non_stop_unique_tokens, data_channel_is_socmed, data_channel_is_tech, kw_min_min, kw_max_min, kw_avg_min, kw_avg_max, kw_min_avg, kw_max_avg, kw_avg_avg, is_weekend, LDA_01, LDA_02, LDA_03

C. Gömülü Yöntem Sonuçları

Random Forest özellik önem sıralaması (ilk 10):

Sıra	Özellik	Önem
1	kw_avg_avg	0.0697
2	kw_max_avg	0.0630
3	self_reference_min_shares	0.0568
4	self_reference_avg_sharess	0.0449
5	LDA_02	0.0378
6	is_weekend	0.0324
7	timedelta	0.0320
8	kw_min_avg	0.0298
9	LDA_01	0.0279
10	self_reference_max_shares	0.0262

D. Model Performans Karşılaştırması

Tablo 3 test seti üzerindeki performans metriklerini karşılaştırmaktadır. Tüm özellikler satırı, özellik seçimi yapılmadan elde edilen temel sonuçları (baseline) göstermektedir.

Yöntem	Özellik Sayısı	Accuracy	Precision	Recall	F1-Score	Eğitim Süresi
Tüm Özellikler (Baseline)	59	65.62%	67.03%	70.01%	68.49%	3.53 sn
Filtreleme (Pearson)	15	64.36%	65.49%	70.20%	67.76%	0.58 sn
Sarmalayıcı (RFE)	15	64.64%	65.94%	69.75%	67.79%	1.31 sn
Gömülü (RF)	15	63.96%	64.41%	72.54%	68.23%	0.75 sn
RFE – Optimal (30 özellik)	30	65.29%	66.64%	69.98%	68.27%	2.03 sn

E. Eğitim / Doğrulama / Test Karşılaştırması

Ödev yönergesine uygun olarak başarı değerleri eğitim (train), doğrulama (5-fold CV) ve test için ayrı ayrı Tablo 4'te verilmiştir.

Yöntem	Eğitim Acc	Eğitim F1	CV Acc (±std)	CV F1 (±std)	Test Acc	Test F1	Eğitim Süresi
Tüm Özellikler (Baseline)	65.57%	68.47%	65.25% ± 0.23%	68.20% ± 0.17%	65.62%	68.49%	3.53s
Filtreleme	64.29%	67.61%	64.31% ± 0.62%	67.63% ± 0.47%	64.36%	67.76%	0.58s
Sarmalayıcı (RFE)	64.83%	67.92%	64.81% ± 0.62%	67.91% ± 0.44%	64.64%	67.79%	1.31s
Gömülü (RF)	63.78%	67.85%	63.86% ± 0.64%	67.88% ± 0.41%	63.96%	68.23%	0.75s
RFE – Optimal (30 özellik)	65.28%	68.31%	65.28% ± 0.34%	68.28% ± 0.39%	65.29%	68.27%	2.03s

F. Seçilen Özellikler ve Ortaklık

Tablo 5'te filtreleme, RFE ve Random Forest yöntemlerinin seçtiği 15'er özellik sıralı olarak verilmiştir. Ortak seçilen özellikler ayrıca listelenmiştir.

Sıra	Filtreleme (Pearson)	Sarmalayıcı (RFE)	Gömülü (RF)
1	LDA_02	n_non_stop_words	kw_avg_avg
2	kw_avg_avg	n_non_stop_unique_tokens	kw_max_avg
3	is_weekend	data_channel_is_socmed	self_reference_min_shares
4	data_channel_is_entertainment	data_channel_is_tech	self_reference_avg_sharess
5	data_channel_is_socmed	kw_min_min	LDA_02
6	weekday_is_saturday	kw_max_min	is_weekend
7	data_channel_is_tech	kw_avg_min	timedelta
8	LDA_04	kw_avg_max	kw_min_avg
9	num_hrefs	kw_min_avg	LDA_01
10	kw_min_avg	kw_max_avg	self_reference_max_shares
11	weekday_is_sunday	kw_avg_avg	data_channel_is_entertainment
12	LDA_01	is_weekend	LDA_04
13	num_keywords	LDA_01	kw_avg_min
14	global_sentiment_polarity	LDA_02	n_unique_tokens
15	global_subjectivity	LDA_03	n_non_stop_unique_tokens

Not: Optimal yöntemde 30 özellik seçilmiştir (performans en yüksek olacak şekilde). Bu özellikler `results/metrics.txt` dosyasında listelenmiştir.

Üç yöntemin de seçtiği ortak özellikler (5 adet):

- `kw_avg_avg` - Ortalama anahtar kelime performansı
- `kw_min_avg` - Minimum anahtar kelime ortalaması
- `LDA_01` - Konu modelleme özelliği 1
- `LDA_02` - Konu modelleme özelliği 2
- `is_weekend` - Hafta sonu yayını


Önemli Bulgu: `kw_avg_avg` ve ilgili anahtar kelime metrikleri tüm yöntemlerde üst sıralarda yer almıştır. Filtreleme yönteminde en yüksek hedef korelasyonu `LDA_02` özelliğinde gözlemlenmiştir.

G. Regularizasyon Analizi

C Değeri	CV Accuracy	Yorum
0.001	64.99%	Güçlü regularizasyon - underfitting
0.01	65.21%	Güçlü regularizasyon
0.1	65.23%	Dengeli
1.0	65.23%	Dengeli
10	65.24%	Zayıf regularizasyon
100	65.25%	Optimal

H. Karışıklık Matrisi

Şekil 1, özellik seçimi yöntemleri arasında en başarılı olan RFE – Optimal (30 özellik) yöntemine ait karışıklık matrisini göstermektedir. **Tablo 6**'da sayısal değerler verilmiştir.




Şekil 1: RFE – Optimal (30 özellik) yöntemi için karışıklık matrisi

Tablo 6: RFE – Optimal (30 özellik) yöntemi için karışıklık matrisi (sayısal değerler).

	Tahmin: 0	Tahmin: 1
Gerçek: 0	2216 (TN)	1482 (FP)
Gerçek: 1	1270 (FN)	2961 (TP)

Yorumlama:

- Specificity (TN Rate): %59.9 - Popüler olmayan haberleri tespit
- Recall (TP Rate): %70.0 - Popüler haberleri tespit
- Model, popüler haberleri yakalamada daha başarılıdır



Şekil 2: Özellik seçimi yöntemlerinin performans karşılaştırması

Şekil 2, farklı özellik seçimi stratejilerinin test seti başarımını görsel olarak karşılaştırmaktadır.

V. Tartışma

A. Yöntemlerin Karşılaştırmalı Analizi

Elde edilen sonuçlar, sarmalayıcı yöntem olan RFE'nin, filtreleme ve gömülü yöntemlere kıyasla daha yüksek performans gösterdiğini ortaya koymuştur. Bunun temel nedeni, RFE'nin özellikler arasındaki etkileşimleri (feature interactions) dikkate alabilmesidir. Filtreleme yöntemi (Pearson korelasyonu), her bir özelliğin hedef değişkenle olan ilişkisini bağımsız olarak değerlendirir; bu durum, tek başına zayıf görünen ancak diğer özelliklerle birleştiğinde güçlü bir ayırt ediciliğe sahip olan özelliklerin elenmesine neden olabilir. RFE ise model tabanlı bir yaklaşım olduğu için özellik gruplarının toplu etkisini değerlendirebilmektedir.

B. Hesaplama Maliyeti ve Performans Dengesi

Tablo 3'teki eğitim süreleri incelendiğinde, filtreleme yönteminin en hızlı (0.58 sn), sarmalayıcı yöntemin (RFE) ise daha yavaş (1.31 sn) olduğu görülmektedir. RFE, her iterasyonda modeli yeniden eğittiği için hesaplama maliyeti yüksektir. Ancak, bu çalışmada RFE ile elde edilen %0.28'lik doğruluk artışı (Filtreleme: %64.36 vs RFE: %64.64), küçük veri setleri için kabul edilebilir bir maliyettir. Büyük veri setlerinde ise filtreleme yöntemleri ön eleme aşaması olarak kullanılabilir.

C. Özelliklerin Yorumlanması

Tüm yöntemlerin ortak olarak seçtiği `kw_avg_avg` (ortalama anahtar kelime performansı) ve `is_weekend` (hafta sonu yayını) özellikleri, haber popülerliğinin hem içerik kalitesiyle hem de yayınlanma zamanıyla güçlü bir ilişkisi olduğunu göstermektedir. Özellikle `LDA` (Latent Dirichlet Allocation) tabanlı konu özelliklerinin (`LDA_01`, `LDA_02`) seçilmesi, haberin konusunun popülerlik üzerinde belirleyici bir etken olduğunu doğrulamaktadır.

D. Boyut Azaltma Etkisi

59 özellikten 30 özelliğe inildiğinde (RFE-Optimal), model performansı %65.62'den %65.29'a düşmüştür. Bu %0.33'lük kayıp istatistiksel olarak ihmal edilebilir düzeydedir. Buna karşılık, modelin karmaşıklığı %50 oranında azaltılmış, böylece aşırı öğrenme (overfitting) riski düşürülmüş ve modelin yorumlanabilirliği artırılmıştır.

E. Sınırlılıklar ve Gelecek Çalışmalar

Bu çalışmada sınıflandırıcı olarak yalnızca Lojistik Regresyon kullanılmıştır. Doğrusal olmayan ilişkileri modelleyebilen SVM veya Gradient Boosting gibi algoritmalar, seçilen özelliklerle daha yüksek performans verebilir. Ayrıca, veri setindeki sınıf dengesizliği (%46 vs %53) hafif düzeyde olsa da, örnekleme yöntemleri (SMOTE vb.) ile performans artırılabilir.

VI. Sonuç

Bu çalışmada, Online News Popularity veri seti üzerinde filtreleme, sarmalayıcı ve gömülü özellik seçimi yöntemlerinin etkinliği karşılaştırmalı olarak analiz edilmiştir. Deneysel sonuçlar ışığında şu çıkarımlar yapılmıştır:

- **En Etkin Yöntem:** Sarmalayıcı yöntem (RFE), özellikler arası etkileşimleri yakalayabilmesi sayesinde en yüksek doğruluğu (%65.29) sağlamıştır.
- **Optimal Özellik Sayısı:** 30 özellik kullanılması, tam özellik setine (59 özellik) kıyasla performansı korurken model karmaşıklığını yarı yarıya azaltmıştır.
- **Kritik Özellikler:** Anahtar kelime metrikleri (kw_avg_avg) ve konu başlıkları (LDA), haber popülerliğini tahmin etmede en belirleyici faktörler olarak tespit edilmiştir.
- **Öneri:** Gerçek zamanlı sistemlerde düşük hesaplama maliyeti için filtreleme yöntemleri, yüksek doğruluk gerektiren analizlerde ise RFE yöntemi tercih edilmelidir.

VII. Referanslar

1. I. Guyon and A. Elisseeff, "An introduction to variable and feature selection," Journal of Machine Learning Research, vol. 3, pp. 1157-1182, 2003.
2. S. Chandrashekar and F. Sahin, "A survey on feature selection methods," Computers & Electrical Engineering, vol. 40, no. 1, pp. 16-28, 2014.
3. I. Guyon et al., "Gene selection for cancer classification using support vector machines," Machine Learning, vol. 46, pp. 389-422, 2002.
4. L. Breiman, "Random forests," Machine Learning, vol. 45, no. 1, pp. 5-32, 2001.
5. K. Fernandes et al., "A proactive intelligent decision support system for predicting the popularity of online news," EPIA 2015, pp. 535-546, 2015.
6. F. Pedregosa et al., "Scikit-learn: Machine learning in Python," Journal of Machine Learning Research, vol. 12, pp. 2825-2830, 2011.