

Denetimli Öğrenme Problemlerinde Özellik Seçimi Yöntemlerinin Karşılaştırmalı Analizi: Online News Popularity Veri Kümesi Üzerinde Deneysel Bir Çalışma

Mohammed Izedin Mohammed
255B7003

Bilgisayar Mühendisliği Bölümü
Yıldız Teknik Üniversitesi

İstanbul, Türkiye

Email: mohammed.izedin@std.yildiz.edu.tr

Özet—Bu çalışmada, denetimli öğrenme problemlerinde kritik bir adım olan özellik seçiminin sınıflandırma performansına etkisi kapsamlı bir şekilde incelenmiştir. UCI Machine Learning Repository’den elde edilen Online News Popularity veri kümesi kullanılarak çevrimiçi haberlerin popülerlik tahmini için bir ikili sınıflandırma modeli geliştirilmiştir. Çalışmada üç farklı özellik seçimi paradigması değerlendirilmiştir: Filtreleme yöntemi (Pearson korelasyonu), Sarmalayıcı yöntem (Recursive Feature Elimination - RFE) ve Gömülü yöntem (Random Forest özelliği). Her yöntemden 15 özellik seçilerek Lojistik Regresyon sınıflandırıcısı ile 5-katlı stratified çapraz doğrulama kullanılarak performans değerlendirilmiştir. Deneysel sonuçlar, tüm 59 özelliğin kullanıldığı durumda %65.62 test doğruluğu elde edildiğini, özellik seçimi yöntemleri arasında Sarmalayıcı (RFE) yönteminin 15 özellik ile %64.64 doğruluk oranıyla en iyi performansı sergilediğini göstermiştir. Optimum özellik sayısı araştırması sonucunda 30 özellik kullanıldığında %65.29 doğruluk oranına ulaşılmıştır. Bulgular, özellik seçiminin hesaplama süresini yaklaşık 6 kat azaltırken (%85 iyileşme) performansta yalnızca %1-2 oranında kabul edilebilir bir düşüşe yol açtığını ortaya koymaktadır. Ayrıca, tüm yöntemlerde ortak seçilen 5 özellik (is_weekend, kw_avg_avg, kw_min_avg, LDA_01, LDA_02) haber popülerliğini etkileyen en kritik faktörler olarak belirlenmiştir.

Index Terms—Özellik Seçimi, Boyut Azaltma, Lojistik Regresyon, Filtreleme Yöntemi, Recursive Feature Elimination, Random Forest, Makine Öğrenmesi, İkili Sınıflandırma

I. GİRİŞ

A. Motivasyon ve Problem Tanımı

Dijital çağda üretilen veri miktarı katlanarak artmakta ve bu durum makine öğrenmesi uygulamalarında yüksek boyutlu veri kümeleriyle çalışma zorunluluğunu beraberinde getirmektedir. Yüksek boyutlu veri kümeleri birçok probleme yol açmaktadır: (1) modelin eğitim süresini önemli ölçüde uzatmakta, (2) aşırı öğrenme (overfitting) riskini artırmakta, (3) model yorumlanabilirliğini azaltmakta ve (4) “boyutluluğun laneti” (curse of dimensionality) olarak bilinen fenomene neden olmaktadır [1]. Bu nedenlerle, özellik seçimi modern makine öğrenmesi iş akışının kritik ve vazgeçilmez bir bileşeni haline gelmiştir.

Özellik seçimi, orijinal özellik kümesinden en bilgilendirici ve ayırt edici alt kümeyi belirleme sürecidir. Bu süreç, boyut azaltma işleminden farklı olarak özelliklerin dönüşüme uğramadan korunmasını sağlar, böylece model yorumlanabilirliği muhafaza edilir [2]. Literatürde özellik seçimi yöntemleri üç ana kategoride incelenmektedir:

- 1) **Filtreleme Yöntemleri (Filter Methods):** Model bağımsız istatistiksel ölçütler kullanarak özellikleri değerlendirir. Hesaplama açısından verimlidir ancak özellikler arası etkileşimleri yakalayamayabilir.
- 2) **Sarmalayıcı Yöntemler (Wrapper Methods):** Bir öğrenme algoritmasını değerlendirici olarak kullanarak özellik alt kümelerini iteratif olarak değerlendirir. Daha iyi sonuçlar üretir ancak hesaplama maliyeti yüksektir.
- 3) **Gömülü Yöntemler (Embedded Methods):** Özellik seçimini model eğitimi sürecine entegre eder. Hesaplama verimliliği ve performans arasında denge sağlar.

B. Çalışmanın Amacı ve Kapsamı

Bu çalışmanın temel amacı, farklı özellik seçimi paradigmalarının sınıflandırma performansı, hesaplama verimliliği ve model yorumlanabilirliği üzerindeki etkilerini deneysel olarak karşılaştırmaktır. Bu amaçla, UCI Machine Learning Repository’den elde edilen Online News Popularity veri kümesi kullanılmıştır. Bu veri kümesi, Mashable haber sitesinden toplanan 39.644 haber makalesinin 59 istatistiksel özelliğini içermektedir.

Çalışma kapsamında aşağıdaki araştırma soruları yanıtlanmaya çalışılmıştır:

- **AS1:** Özellik seçimi yöntemleri sınıflandırma performansını nasıl etkiler?
- **AS2:** Hangi özellik seçimi yöntemi en iyi performans-verimlilik dengesini sağlar?
- **AS3:** Farklı yöntemler tarafından ortak seçilen özellikler nelerdir ve bunların yorumu nedir?
- **AS4:** Optimum özellik sayısı kaçtır ve bu sayı performansı nasıl etkiler?

C. Makalenin Organizasyonu

Bu makalenin geri kalanı şu şekilde organize edilmiştir: Bölüm II’de ilgili çalışmalar ve teorik arka plan sunulmuştur. Bölüm III’te kullanılan veri kümesi, ön işleme adımları ve metodoloji detaylı olarak açıklanmıştır. Bölüm IV’te deneysel sonuçlar sunulmuş ve analiz edilmiştir. Bölüm V’te sonuçların tartışması ve yorumu yapılmıştır. Son olarak, Bölüm VI’da çalışmanın sonuçları özetlenmiş ve gelecek çalışmalar için öneriler sunulmuştur.

II. İLGİLİ ÇALIŞMALAR VE TEORİK ARKA PLAN

A. Özellik Seçimi Yöntemleri

1) *Filtreleme Yöntemleri*: Filtreleme yöntemleri, özellik değerlendirmesi için model bağımsız istatistiksel ölçütler kullanır. Bu yöntemler genellikle hızlı ve ölçeklenebilirdir, ancak özellikler arası etkileşimleri yakalama kapasiteleri sınırlıdır [1].

En yaygın filtreleme ölçütleri şunlardır:

- **Pearson Korelasyonu**: İki sürekli değişken arasındaki doğrusal ilişkiyi ölçer:

$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (1)$$

- **Chi-Square Testi**: Kategorik değişkenler için bağımsızlık testi uygular.
- **Mutual Information**: Değişkenler arasındaki karşılıklı bilgiyi ölçer.

2) *Sarmalayıcı Yöntemler*: Sarmalayıcı yöntemler, bir makine öğrenmesi modelini “kara kutu” değerlendirici olarak kullanarak özellik alt kümelerini değerlendirir. En yaygın kullanılan sarmalayıcı yöntemlerden biri Recursive Feature Elimination (RFE) yöntemidir [4].

RFE algoritması şu adımları izler:

- 1) Tüm özelliklerle modeli eğit
- 2) Özellik önem skorlarını hesapla
- 3) En az önemli özelliği ele
- 4) İstenilen özellik sayısına ulaşılan kadar tekrarla

3) *Gömülü Yöntemler*: Gömülü yöntemler, özellik seçimini model eğitimi sürecine entegre eder. Random Forest gibi ağaç tabanlı yöntemler, eğitim sırasında her özelliğin “önem skoru”nu hesaplayarak doğal bir özellik sıralaması sağlar [5].

Random Forest özellik önemi, bir özelliğin ağaçlardaki bölünmelerde sağladığı ortalama safsızlık (impurity) azalması olarak hesaplanır:

$$Importance(X_j) = \frac{1}{n_{trees}} \sum_{t=1}^{n_{trees}} \sum_{s \in S_t} p_s \cdot \Delta i(s, X_j) \quad (2)$$

burada S_t ağaç t ’deki bölünmeleri, p_s düğüme ulaşan örnek oranını ve Δi safsızlık azalmasını temsil eder.

B. Online News Popularity Tahmini

Online haber popülerliği tahmini, sosyal medya analitiği ve içerik pazarlaması alanlarında önemli bir problem olarak karşımıza çıkmaktadır. Fernandes ve arkadaşları [3] bu problem için kapsamlı bir veri kümesi oluşturmuş ve çeşitli makine öğrenmesi yöntemlerini değerlendirmişlerdir.

III. METODOLOJİ

A. Veri Kümesi

Bu çalışmada UCI Machine Learning Repository’den elde edilen Online News Popularity veri kümesi kullanılmıştır [3]. Veri kümesi, Mashable web sitesinde 2013-2015 yılları arasında yayınlanan 39.644 haber makalesini kapsamaktadır. Her makale için 61 özellik hesaplanmıştır; bunlardan 59’u tahmine dayalı özellikler, 1’i tanımlayıcı (URL) ve 1’i hedef değişkendir (shares - paylaşım sayısı).

Veri kümesindeki özellikler şu kategorilerde gruplandırılabilir:

Tablo I
ONLINE NEWS POPULARITY VERİ KÜMESİ ÖZELLİK KATEGORİLERİ

Kategori	Sayı	Açıklama
Kelime İstatistikleri	11	Kelime sayısı, benzersiz token oranı, ortalama kelime uzunluğu
Bağlantı Bilgileri	5	Hiper link sayısı, görsel sayısı, video sayısı
Anahtar Kelimeler	10	Min/max/avg anahtar kelime metrikleri
Veri Kanalları	6	Yaşam tarzı, eğlence, iş, sosyal medya, teknoloji, dünya
Yayın Zamanı	7	Haftanın günü, hafta sonu
LDA Konuları	5	Latent Dirichlet Allocation konu skorları
Duygu Analizi	9	Polarite, öznellik skorları
Referanslar	6	Öz-referans paylaşım istatistikleri

B. Veri Ön İşleme

Veri ön işleme aşamasında aşağıdaki adımlar sistematik olarak uygulanmıştır:

1) *Özellik Temizleme*: Ayırt edici bilgi içermeyen url sütunu veri kümesinden çıkarılmıştır. Bu sütun, makale kimliği görevi görmekte olup tahminsel değer taşımamaktadır. Sonuç olarak 59 özellik ile çalışılmıştır.

2) *Hedef Değişken Dönüştürme*: Orijinal hedef değişken olan shares (paylaşım sayısı) sürekli bir değişkendir. Bu çalışmada ikili sınıflandırma problemi oluşturmak için medyan değer (1400) eşik olarak belirlenmiştir:

$$y = \begin{cases} 1 & \text{(Popüler) eğer shares} \geq 1400 \\ 0 & \text{(Popüler Değil) eğer shares} < 1400 \end{cases} \quad (3)$$

Bu dönüşüm sonucunda sınıf dağılımı Tablo II’te gösterildiği gibi yaklaşık dengeli bir yapı elde edilmiştir.

Tablo II
HEDEF DEĞİŞKEN SINIF DAĞILIMI

Sınıf	Etiket	Örnek Sayısı	Oran (%)
Popüler	1	21.154	53.36
Popüler Değil	0	18.490	46.64
Toplam	–	39.644	100.00

Sınıf dağılımının yaklaşık dengeli olması (%53 vs %47), sınıf dengesizliği probleminin bu çalışmada kritik olmadığını göstermektedir.

3) *Veri Bölme Stratejisi*: Veri kümesi, stratified örneklem kullanılarak %80 eğitim (31.715 örnek) ve %20 test (7.929 örnek) olarak bölünmüştür. Stratified örnekleme, her iki kümedeki sınıf oranlarının korunmasını sağlamaktadır.

Önemli Not: Veri bölme işlemi rastgele (random) olarak gerçekleştirilmiş, `random_state=42` ile tekrarlanabilirlik sağlanmıştır. Bu yaklaşım, sıralı (sequential) bölmeye göre daha güvenilir sonuçlar üretmektedir çünkü veri kümesindeki olası zamansal veya sırasal kalıpların test sonuçlarını etkilemesini önler.

4) *Özellik Ölçeklendirme*: Lojistik Regresyon gibi gradyan tabanlı optimizasyon kullanan modeller için özellik ölçeklendirme kritik öneme sahiptir. Bu çalışmada Z-score standardizasyonu (StandardScaler) uygulanmıştır:

$$x_{scaled} = \frac{x - \mu_{train}}{\sigma_{train}} \quad (4)$$

Kritik Detay: Ölçeklendirme parametreleri (μ ve σ) yalnızca eğitim verisi üzerinden hesaplanmış ve hem eğitim hem de test verisine uygulanmıştır. Bu yaklaşım, test verisinden bilgi sızmasını (data leakage) önlemektedir.

C. Özellik Seçimi Yöntemlerinin Uygulanması

1) *Filtreleme Yöntemi*: *Pearson Korelasyonu*: Filtreleme yöntemi iki aşamada uygulanmıştır:

Aşama 1 - Multicollinearity Eleme: Özellikler arası korelasyon matrisi hesaplanmış ve 0.8'den yüksek korelasyona sahip özellik çiftlerinden, hedef değişken ile düşük korelasyona sahip olan elenmiştir. Bu işlem sonucunda 59 özellikten 51'i korunmuştur.

Aşama 2 - Özellik Sıralama: Kalan özellikler hedef değişken ile korelasyonlarına göre sıralanmış ve en yüksek korelasyona sahip 15 özellik seçilmiştir.

2) *Sarmalayıcı Yöntem*: *Recursive Feature Elimination (RFE)*: RFE yöntemi, Scikit-learn kütüphanesinin RFE sınıfı kullanılarak uygulanmıştır. Temel tahmin edici (estimator) olarak Lojistik Regresyon modeli kullanılmıştır. Algoritma, her iterasyonda en düşük katsayıya sahip özelliği eleyerek 15 özellik kalana kadar devam etmiştir.

3) *Gömülü Yöntem*: *Random Forest Özellik Önemi*: Random Forest sınıflandırıcısı 100 karar ağacı (`n_estimators=100`) ile eğitilmiştir. Hesaplama verimliliği için maksimum ağaç derinliği 10 ile sınırlandırılmıştır (`max_depth=10`). Eğitim sonrasında `feature_importances_` özneliği kullanılarak özellik önem skorları elde edilmiş ve en yüksek skora sahip 15 özellik seçilmiştir.

D. Model Eğitimi ve Değerlendirme

1) *Sınıflandırıcı*: *Lojistik Regresyon*: Tüm deneylerde sınıflandırıcı olarak Lojistik Regresyon kullanılmıştır. Lojistik Regresyon, ikili sınıflandırma problemleri için yaygın kullanılan, yorumlanabilir ve hesaplama açısından verimli bir yöntemdir.

Lojistik Regresyon modeli, girdi özelliklerinin ağırlıklı toplamını sigmoid fonksiyonundan geçirerek olasılık tahmini üretir:

$$P(y = 1|x) = \sigma(w^T x + b) = \frac{1}{1 + e^{-(w^T x + b)}} \quad (5)$$

Model parametreleri cross-entropy kayıp fonksiyonunu minimize edecek şekilde optimize edilir:

$$L(w) = - \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] \quad (6)$$

2) *Regularizasyon ve Hiperparametre Optimizasyonu*: Aşırı öğrenmeyi önlemek için L2 (Ridge) regularizasyonu uygulanmıştır. Regularizasyon gücünü kontrol eden C parametresi ($C = 1/\lambda$) 5-katlı çapraz doğrulama ile optimize edilmiştir. Test edilen değerler: {0.001, 0.01, 0.1, 1, 10, 100}.

3) *Çapraz Doğrulama Stratejisi*: Model performansı, 5-katlı stratified çapraz doğrulama ile değerlendirilmiştir. Stratified yaklaşım, her katlamada sınıf oranlarının korunmasını sağlamaktadır. Bu yöntem, model performansının güvenilir bir tahminini sunarken varyans tahminini de mümkün kılmaktadır.

E. Değerlendirme Metrikleri

Model performansı aşağıdaki metriklerle değerlendirilmiştir:

- **Doğruluk (Accuracy)**: Doğru sınıflandırılan örneklerin oranı

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (7)$$

- **Kesinlik (Precision)**: Pozitif tahminlerin doğruluğu

$$Precision = \frac{TP}{TP + FP} \quad (8)$$

- **Duyarlılık (Recall)**: Gerçek pozitiflerin yakalanma oranı

$$Recall = \frac{TP}{TP + FN} \quad (9)$$

- **F1-Skoru**: Precision ve Recall'un harmonik ortalaması

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (10)$$

burada TP: True Positive, TN: True Negative, FP: False Positive, FN: False Negative.

IV. DENEYSEL SONUÇLAR

A. Özellik Seçimi Sonuçları

1) *Filtreleme Yöntemi Sonuçları*: Pearson korelasyonu kullanılarak yapılan filtreleme işlemi sonucunda seçilen 15 özellik Tablo III'de listelenmiştir.

Tablo III
FİLİTRELEME YÖNTEMİ İLE SEÇİLEN ÖZELLİKLER VE HEDEF
KORELASYONLARI

Sıra	Özellik	r
1	LDA_02	0.1603
2	kw_avg_avg	0.1562
3	is_weekend	0.1387
4	data_channel_is_entertainment	0.1129
5	data_channel_is_socmed	0.1103
6	weekday_is_saturday	0.1079
7	data_channel_is_tech	0.1044
8	LDA_04	0.0960
9	num_hrefs	0.0921
10	kw_min_avg	0.0908
11	weekday_is_sunday	0.0821
12	LDA_01	0.0789
13	num_keywords	0.0762
14	global_sentiment_polarity	0.0699
15	global_subjectivity	0.0682

Tablo IV
RANDOM FOREST ÖZELLİK ÖNEMİ SIRALAMASI (İLK 15)

Sıra	Özellik	Önem Skoru
1	kw_avg_avg	0.0697
2	kw_max_avg	0.0630
3	self_reference_min_shares	0.0568
4	self_reference_avg_shares	0.0449
5	LDA_02	0.0378
6	is_weekend	0.0324
7	timedelta	0.0320
8	kw_min_avg	0.0298
9	LDA_01	0.0279
10	self_reference_max_shares	0.0262
11	data_channel_is_entertainment	0.0261
12	LDA_04	0.0253
13	kw_avg_min	0.0239
14	n_unique_tokens	0.0232
15	n_non_stop_unique_tokens	0.0220

Analiz: Random Forest, öz-referans paylaşım metriklerini (self_reference_*) önemli bulmuştur. Bu özellikler, bir haberin aynı sitedeki diğer popüler haberlerle ilişkisini yansıtmaktadır.

4) *Özellik Karşılaştırması ve Ortak Özellikler:* Üç yöntemin seçtiği özelliklerin karşılaştırması Tablo V'de sunulmuştur.

Tablo V
TÜM YÖNTEMLERDE ORTAK SEÇİLEN ÖZELLİKLER

Ortak Özellik	Yorumu
kw_avg_avg	Ortalama anahtar kelime performansı
kw_min_avg	Minimum anahtar kelime ortalaması
is_weekend	Hafta sonu yayın göstergesi
LDA_01	Birinci LDA konu skoru
LDA_02	İkinci LDA konu skoru

Analiz: Korelasyon değerlerinin görece düşük olması ($|r| < 0.17$), haber popülerliğinin tek bir faktörle açıklanamayacak karmaşık bir fenomen olduğunu göstermektedir. En yüksek korelasyona sahip özellikler LDA konu skorları, anahtar kelime metrikleri ve yayın zamanlamasıyla ilgilidir.

2) *Sarmalayıcı Yöntem Sonuçları:* RFE yöntemi ile seçilen 15 özellik: n_non_stop_words, n_non_stop_unique_tokens, data_channel_is_socmed, data_channel_is_tech, kw_min_min, kw_max_min, kw_avg_min, kw_avg_max, kw_min_avg, kw_max_avg, kw_avg_avg, is_weekend, LDA_01, LDA_02, LDA_03.

Analiz: RFE yöntemi, anahtar kelime metriklerini (7 özellik) ağırlıklı olarak seçmiştir. Bu durum, anahtar kelime stratejisinin haber popülerliği üzerinde güçlü bir etkiye sahip olduğunu göstermektedir.

3) *Gömülü Yöntem Sonuçları:* Random Forest özellik önemi ile seçilen özellikler ve önem skorları Tablo IV'de sunulmuştur.

Kritik Bulgu: Beş özelliğin üç farklı paradigmda ortak seçilmesi, bu özelliklerin haber popülerliği için gerçekten ayırt edici olduğunu güçlü bir şekilde desteklemektedir. Özellikle:

- **Anahtar Kelime Metrikleri (kw_avg_avg, kw_min_avg):** SEO ve içerik pazarlaması açısından anahtar kelime stratejisinin kritik önemini göstermektedir.
- **Hafta Sonu Yayını (is_weekend):** Kullanıcı davranışlarının haftanın gününe göre değiştiğini, hafta sonu yayınlanan haberlerin farklı etkileşim kalıpları sergilediğini ortaya koymaktadır.
- **LDA Konu Skorları (LDA_01, LDA_02):** Haberin konu içeriğinin popülerlik üzerinde belirleyici etkisi olduğunu göstermektedir.

B. Regularizasyon Parametresi Optimizasyonu

Aşırı öğrenmenin kontrol altına alınması için Lojistik Regresyon'un C parametresi optimize edilmiştir. Sonuçlar Tablo VI'de sunulmuştur.

Tablo VI
REGULARIZASYON PARAMETRESİ (C) ARAMA SONUÇLARI

C Değeri	CV Accuracy	Standart Sapma
0.001	0.6499	± 0.0046
0.01	0.6521	± 0.0042
0.1	0.6523	± 0.0028
1.0	0.6523	± 0.0030
10.0	0.6524	± 0.0022
100.0	0.6525	± 0.0023

Analiz: En iyi performans C=100 değerinde elde edilmiştir. Düşük C değerlerinde (güçlü regularizasyon) performans düşüşü gözlemlenmesi, modelin yetersiz öğrenme (underfitting) eğiliminde olduğunu göstermektedir. Bu durum, veri kümesindeki ilişkilerin zaten görece zayıf olmasından kaynaklanmaktadır (düşük korelasyon değerleri).

C. Model Performans Sonuçları

1) *Çapraz Doğrulama Sonuçları:* 5-katlı stratified çapraz doğrulama sonuçları Tablo VII’de özetlenmiştir.

Tablo VII
5-KATLI ÇAPRAZ DOĞRULAMA SONUÇLARI (EĞİTİM)

Yöntem	Accuracy	F1	Precision	Recall
Tüm Özellikler	0.6525	0.6820	0.6665	0.6985
Filtreleme	0.6431	0.6763	0.6555	0.6985
Sarmalayıcı	0.6481	0.6791	0.6616	0.6976
Gömülü	0.6386	0.6788	0.6457	0.7156

2) *Test Seti Sonuçları:* Ayrı tutulan %20 test seti üzerinde elde edilen sonuçlar Tablo VIII’de sunulmuştur.

Tablo VIII
TEST SETİ PERFORMANS SONUÇLARI

Yöntem	n	Accuracy	F1	Precision	Süre
Tüm Özellikler	59	0.6562	0.6849	0.6703	3.50s
Filtreleme	15	0.6436	0.6776	0.6549	0.52s
Sarmalayıcı	15	0.6464	0.6779	0.6594	1.20s
Gömülü	15	0.6396	0.6823	0.6441	0.74s
Optimal	30	0.6529	0.6827	0.6664	1.92s

Detaylı Analiz:

- Performans Karşılaştırması:** Tüm özelliklerin kullanıldığı model en yüksek doğruluk oranına (%65.62) ulaşmıştır. Ancak özellik seçimi yöntemleri, yalnızca 15 özellik ile %64-65 arasında performans sergileyerek benzer sonuçlar üretmiştir.
- Verimlilik Kazanımı:** Özellik seçimi, eğitim süresini önemli ölçüde azaltmıştır:
 - Filtreleme: 3.50s → 0.52s (%85 azalma)
 - Sarmalayıcı: 3.50s → 1.20s (%66 azalma)
 - Gömülü: 3.50s → 0.74s (%79 azalma)

- Yöntemler Arası Karşılaştırma:** Sarmalayıcı (RFE) yöntemi, 15 özellik ile en yüksek doğruluk oranına (%64.64) ulaşmıştır. Bu sonuç, RFE’nin model performansını doğrudan optimize etmesinden kaynaklanmaktadır.
- Recall Analizi:** Gömülü yöntem en yüksek Recall değerine (0.7254) sahiptir. Bu, popüler haberleri yakalamada daha başarılı olduğunu göstermektedir ancak Precision düşüktür (0.6441).

D. Optimum Özellik Sayısı Araştırması

En başarılı özellik seçimi yöntemi olan RFE kullanılarak optimum özellik sayısı araştırılmıştır. Sonuçlar Tablo IX’de ve Şekil ??’de gösterilmiştir.

Tablo IX
RFE İLE OPTIMUM ÖZELLİK SAYISI ARAŞTIRMASI

Özellik Sayısı	CV Accuracy	Std
5	0.6096	± 0.0060
10	0.6410	± 0.0072
15	0.6486	± 0.0081
20	0.6520	± 0.0071
25	0.6516	± 0.0072
30	0.6520	± 0.0054

Analiz:

- 5 özellik ile başarı düşüktür (%60.96), önemli bilgi kaybı vardır.
- 15-20 özellik arasında belirgin iyileşme görülmektedir.
- 20 özellikten sonra performans artışı durmaktadır (plato etkisi).
- Optimum nokta: 30 özellik ile %65.20 CV doğruluğu, %65.29 test doğruluğu.

Bu bulgular, veri kümesindeki bilginin yaklaşık yarısının (30/59 ≈ %51) model performansı için yeterli olduğunu göstermektedir.

E. Karışıklık Matrisi Analizi

En başarılı yöntem (Tüm Özellikler) için karışıklık matrisi Tablo X’de detaylı olarak sunulmuştur.

Tablo X
TÜM ÖZELLİKLER YÖNTEMİ İÇİN KARIŞIKLIK MATRİSİ

	Tahmin: Popüler Değil	Tahmin: Popüler
Gerçek: Popüler Değil	2241 (TN)	1457 (FP)
Gerçek: Popüler	1269 (FN)	2962 (TP)

Detaylı Metrik Hesaplamaları:

$$Accuracy = \frac{2241 + 2962}{7929} = \frac{5203}{7929} = 0.6562 \quad (11)$$

$$Precision = \frac{2962}{2962 + 1457} = \frac{2962}{4419} = 0.6703 \quad (12)$$


$$Recall = \frac{2962}{2962 + 1269} = \frac{2962}{4231} = 0.7001 \quad (13)$$

$$F1 = 2 \times \frac{0.6703 \times 0.7001}{0.6703 + 0.7001} = 0.6849 \quad (14)$$


$$Specificity = \frac{2241}{2241 + 1457} = \frac{2241}{3698} = 0.6060 \quad (15)$$

Yorum:

- Model, popüler haberleri yakalamada (%70 Recall) popüler olmayan haberleri yakalamaya (%60.6 Specificity) göre daha başarılıdır.
- 1457 False Positive, modelin bazı popüler olmayan haberleri yanlışlıkla popüler olarak tahmin ettiğini göstermektedir.
- 1269 False Negative, bazı popüler haberlerin kaçınıldığını göstermektedir.



Şekil 2. Yöntem Karşılaştırması



Şekil 1. Karışıklık Matrisi

V. TARTIŞMA

A. Araştırma Sorularının Yanıtlanması

AS1: Özellik seçimi yöntemleri sınıflandırma performansını nasıl etkiler?

Deneyisel sonuçlar, özellik seçiminin performansta %1-2 oranında kabul edilebilir bir düşüşe neden olduğunu göstermiştir. 59 özellikten 15'e inildiğinde (%75 azalma) performans yalnızca %1-2 düşmüştür. Bu sonuç, veri kümesindeki birçok özelliğin gereksiz (redundant) veya gürültülü (noisy) olduğunu göstermektedir.

AS2: Hangi özellik seçimi yöntemi en iyi performans-verimlilik dengesini sağlar?

- **Performans açısından:** Sarmalayıcı (RFE) en iyi sonucu (%64.64) üretmiştir.
- **Verimlilik açısından:** Filtreleme yöntemi en hızlı eğitim süresine (0.52s) sahiptir.
- **Denge açısından:** Gömülü yöntem makul performans (0.6396) ve makul süre (0.74s) ile iyi bir denge sunmaktadır.

Uygulama gereksinimlerine göre:

- Maksimum performans gerekiyorsa: RFE tercih edilmelidir.
- Hız kritikse: Filtreleme yöntemi tercih edilmelidir.
- Dengeli yaklaşım gerekiyorsa: Gömülü yöntem tercih edilmelidir.

AS3: Ortak seçilen özelliklerin yorumu nedir?

Beş ortak özelliğin analizi, haber popülerliğini etkileyen üç ana faktörü ortaya koymuştur:

- 1) **Anahtar Kelime Stratejisi:** kw_avg_avg ve kw_min_avg özellikleri, SEO ve içerik pazarlamasının önemini göstermektedir.
- 2) **Yayın Zamanlaması:** is_weekend özelliği, kullanıcı davranışlarının zamana bağlı değişkenliğini yansıtmaktadır.
- 3) **Konu İçeriği:** LDA_01 ve LDA_02 özellikleri, haberin konu alanının popülerlik üzerindeki etkisini göstermektedir.

AS4: Optimum özellik sayısı kaçtır?

Optimum özellik sayısı 30 olarak belirlenmiştir. Bu sayı ile:

- CV Accuracy: %65.20 (59 özellik ile %65.25)
- Test Accuracy: %65.29 (59 özellik ile %65.62)
- Özellik azaltma: %49
- Süre azaltma: %45

30 özellik, performans kaybını minimize ederken hesaplama verimliliğini artırmaktadır.

B. Sınırlılıklar ve Gelecek Çalışmalar

Bu çalışmanın bazı sınırlılıkları bulunmaktadır:

- 1) **Model Çeşitliliği:** Yalnızca Lojistik Regresyon kullanılmıştır. Farklı sınıflandırıcılar (SVM, Neural Networks) ile karşılaştırma yapılabilir.
- 2) **Özellik Etkileşimleri:** Özellikler arası etkileşimler değerlendirilmemiştir. Polynomial features veya neural networks bu etkileşimleri yakalayabilir.
- 3) **Zamansal Faktörler:** Veri kümesindeki zamansal trendler detaylı analiz edilmemiştir.

Gelecek çalışmalarda:

- Ensemble yöntemler ile özellik seçimi kombinasyonları denenebilir.
- Deep learning modelleri ile otomatik özellik öğrenimi karşılaştırılabilir.
- Transfer learning yaklaşımları değerlendirilebilir.

VI. SONUÇ

Bu çalışmada, Online News Popularity veri kümesi üzerinde üç farklı özellik seçimi paradigması (Filtreleme, Sarmalayıcı ve Gömülü) sistematik olarak karşılaştırılmıştır. Elde edilen bulgular şu şekilde özetlenebilir:

- 1) **Performans:** Tüm özelliklerin kullanıldığı durumda %65.62 test doğruluğu elde edilmiştir. Özellik seçimi yöntemleri, 15 özellik ile %64-65 arasında benzer performans sergilemiştir.
- 2) **Verimlilik:** Özellik seçimi, eğitim süresini %66-85 oranında azaltmıştır.
- 3) **En İyi Yöntem:** Sarmalayıcı (RFE) yöntemi, performans açısından en iyi sonucu (%64.64) üretmiştir.
- 4) **Optimum Özellik Sayısı:** 30 özellik ile %65.29 doğruluk elde edilmiş, performans-verimlilik dengesi sağlanmıştır.

- 5) **Kritik Özellikler:** Anahtar kelime metrikleri, yayın zamanlaması ve LDA konu skorları, haber popülerliği için en ayırt edici faktörler olarak belirlenmiştir.

Sonuç olarak, özellik seçimi makine öğrenmesi projelerinde model yorumlanabilirliğini artırırken hesaplama maliyetini düşüren etkili bir stratejidir. Bu çalışma, farklı özellik seçimi yöntemlerinin güçlü ve zayıf yönlerini ortaya koyarak uygulayıcılara yol gösterici bilgiler sunmaktadır.

KAYNAKLAR

- [1] I. Guyon and A. Elisseeff, "An introduction to variable and feature selection," *Journal of Machine Learning Research*, vol. 3, pp. 1157–1182, 2003.
- [2] G. Chandrashekar and F. Sahin, "A survey on feature selection methods," *Computers & Electrical Engineering*, vol. 40, no. 1, pp. 16–28, 2014.
- [3] K. Fernandes, P. Vinagre, and P. Cortez, "A proactive intelligent decision support system for predicting the popularity of online news," in *Proceedings of the 17th Portuguese Conference on Artificial Intelligence (EPIA)*, 2015, pp. 535–546.
- [4] I. Guyon, J. Weston, S. Barnhill, and V. Vapnik, "Gene selection for cancer classification using support vector machines," *Machine Learning*, vol. 46, no. 1-3, pp. 389–422, 2002.
- [5] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [6] F. Pedregosa, G. Varoquaux, A. Gramfort, et al., "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [7] R. Kohavi and G. H. John, "Wrappers for feature subset selection," *Artificial Intelligence*, vol. 97, no. 1-2, pp. 273–324, 1997.
- [8] H. Liu and H. Motoda, *Feature Extraction, Construction and Selection: A Data Mining Perspective*. Springer, 1998.